

Atividade V

Agrupamento: BSAS, Janelas de Parzen e KNN

Ryan Alves

09 de maio de 2026

Pré-processamento (comum às três propostas). Os datasets *Iris* (150×4) e *Wine* (178×13) têm *features* em escalas muito diferentes (*Wine*: **proline** na ordem das centenas *vs.* **nonflavanoid_phenols** < 1). Como BSAS, k-means, Parzen e KNN-grafo usam distância Euclidiana, foi feita a padronização via *z-score*. PCA 2D é usado apenas para visualização — o agrupamento opera no espaço completo.



Figura 1: Projeção PCA 2D dos dois datasets com os rótulos verdadeiros. No *Iris*, **setosa** é linearmente separável, mas **versicolor/virginica** se sobrepõem. No *Wine*, as três classes são contíguas e anisotrópicas.

1 Atividade 1 — BSAS combinado com k-means

Implemente uma proposta que combine o método BSAS com outro método de agrupamento discutido na disciplina. Nessa proposta, o método BSAS deve ser utilizado com a finalidade de estimar o número de agrupamentos presentes no conjunto de dados, enquanto o segundo método deve ser responsável pelo particionamento efetivo dos dados. Como sugestão, explore a relação entre o número de agrupamentos retornado pelo BSAS e o parâmetro de limiar τ . A noção de derivada, ou alguma aproximação numérica equivalente, pode ser útil na identificação de regiões de estabilidade ou transições mais bruscas, auxiliando na escolha do número de agrupamentos.

1.1 Proposta

BSAS para estimar k ; k-means para particionar. O BSAS percorre os pontos uma vez; cada ponto vai para o centroide mais próximo se a distância for $\leq \tau$, senão cria novo cluster (até o limite q). É sensível à ordem dos pontos e a τ , mas seu *output* — número de clusters $k(\tau)$ — contém informação estrutural útil.

Estimativa de k via varredura em τ + plateaus. Para uma grade de 300 valores de τ entre $0,02 \cdot D$ e $1,2 \cdot D$ (com D = diâmetro do dataset padronizado), foi executado o BSAS **80**

vezes com permutações aleatórias dos pontos e tomada a **mediana** de k por τ (reduz o ruído da ordem). A curva resultante é alisada com **medfilt** (janela 7).

Aproximação da derivada. Foram identificados **plateaus** — trechos consecutivos de τ onde $k(\tau)$ é constante. Em cada plateau, $\partial k / \partial \tau \approx 0$ (estabilidade); nas transições entre plateaus, $|\partial k / \partial \tau| \gg 0$ (mudanças bruscas). A largura do plateau em τ é a medida de estabilidade. Heurística adotada: **plateau mais largo, com desempate pelo menor k (parcimônia)**; plateaus em $k = q$ são descartados (regime saturado).

1.2 Resultados




Figura 2: Curva $k(\tau)$ (mediana de 80 permutações + **medfilt**). A faixa laranja destaca o plateau mais largo (top-1) usado para estimar k .

Top-3 plateaus.

- **Iris:** $k = 2$ ($\Delta\tau = 0,631$), $k = 3$ ($\Delta\tau = 0,365$), $k = 5$ ($\Delta\tau = 0,266$). O plateau dominante em $k = 2$ corresponde à separação **setosa** *vs.* resto.
- **Wine:** $k = 2$, $k = 6$, $k = 9$ — **todos com largura idêntica** $\Delta\tau = 0,221$. A geometria anisotrópica das três classes gera múltiplas regiões de estabilidade equivalentes; o desempate por menor k escolhe $k = 2$.




Figura 3: *Iris* — BSAS+KMeans com $k = 2$. ARI = 0,568; NMI = 0,734.




Figura 4: *Wine* — BSAS+KMeans com $k = 2$. ARI = 0,374; NMI = 0,478. O subagrupamento (deveriam ser 3 classes) e a fronteira esférica do k-means não acomodam bem as classes anisotrópicas.

2 Atividade 2 — Agrupamento com Janelas de Parzen e KNN

Proponha e implemente dois procedimentos de agrupamento fazendo uso dos métodos Janelas de Parzen e KNN, respectivamente. Explore e acredite na sua criatividade. Aplique as propostas implementadas aos conjuntos “Wine Dataset” e “Iris Dataset”, e avalie os resultados de forma qualitativa.

Observação sobre KNN/SVM como agrupamento. KNN e SVM, no sentido clássico, são *supervisionados*. Aqui o KNN aparece **adaptado** como ferramenta de agrupamento via **grafo de vizinhos mútuos**, conforme detalhado adiante.

2.1 Proposta 2a — Janelas de Parzen + *mean-shift*

Ideia. Estima-se a densidade

$$\hat{p}(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

com kernel gaussiano. Aplica-se *mean-shift* a partir de cada ponto: a cada iteração, $x \leftarrow \sum_i w_i x_i / \sum_i w_i$ com $w_i = K((x - x_i)/h)$, fazendo o ponto subir o gradiente da densidade até um modo. Pontos que convergem ao mesmo modo formam um cluster.

Escolha de h . Bandwidth controla a suavidade: h pequeno gera muitos modos espúrios; h grande funde tudo. Foi adotado o mesmo princípio do BSAS — foi feita uma varredura em h , buscando o **plateau mais largo no número de modos detectados**, comparando com a estimativa de Silverman como referência.




Figura 5: Número de modos detectados *vs.* h . Linha laranja: h escolhido pelo plateau; linha cinza pontilhada: estimativa de Silverman (apenas referência).




Figura 6: Topo: densidade Parzen no espaço PCA 2D (ilustrativa). Base: clusters obtidos pelo *mean-shift* no espaço original. *Iris*: $k = 2$, $ARI = 0,568$. *Wine*: $k = 3$, $ARI = 0,815$, $NMI = 0,812$ — recupera as três classes verdadeiras.

2.2 Proposta 2b — KNN como ferramenta de agrupamento (grafo mútuo)

Ideia. Cada ponto liga-se aos seus k_{nb} vizinhos mais próximos; são mantidas apenas as **arestas mútuas** ($i \leftrightarrow j$ se e somente se $j \in KNN(i)$ e $i \in KNN(j)$). As **componentes conexas** do grafo resultante são os clusters. Componentes minúsculas (tamanho $< 5\%$ de N) são absorvidas no cluster grande mais próximo.

Escolha de k_{nb} . Conforme k_{nb} cresce, o grafo passa de muitas componentes pequenas para uma componente gigante. Critério (sem usar rótulos): entre k_{nb} com **dominância** $< 70\%$ (fração do maior cluster) e $K_{post} \geq 2$, escolher o de **menor** K_{post} (parcimônia); desempate por **maior entropia** dos tamanhos.




Figura 7: Diagnóstico da escolha de k_{nb} : número de clusters pós-reassign (verde) e dominância (cinza). Linha laranja: $k_{nb} = 6$ escolhido em ambos os datasets.




Figura 8: *Iris* — KNN-grafo mútuo, $k_{nb} = 6$, $k = 2$. ARI = 0,568; NMI = 0,734.




Figura 9: *Wine* — KNN-grafo mútuo, $k_{nb} = 6$, $k = 3$. ARI = 0,867; NMI = 0,848 — **melhor resultado entre as três propostas.**

3 Comparação consolidada

Dataset	Método	k	ARI	NMI
<i>Iris</i>	BSAS + k-means	2	0,568	0,734
<i>Iris</i>	Parzen + <i>mean-shift</i>	2	0,568	0,734
<i>Iris</i>	KNN-grafo mútuo	2	0,568	0,734
<i>Wine</i>	BSAS + k-means	2	0,374	0,478
<i>Wine</i>	Parzen + <i>mean-shift</i>	3	0,815	0,812
<i>Wine</i>	KNN-grafo mútuo	3	0,867	0,848

Tabela 1: ARI e NMI são usados **post-hoc** (apenas para avaliação). Nenhuma escolha de hiperparâmetro (τ , h , k_{nb}) usou rótulos: todas vieram de critérios intrínsecos — largura de plateau, dominância, entropia.

4 Discussão crítica

BSAS + k-means. A varredura $k(\tau)$ + plateaus oferece um critério não-supervisionado para estimar k , mas o BSAS é **sensível à ordem dos pontos** (mitigado pela mediana de 80 permutações) e ao próprio τ . No *Iris* é capturada a separação **setosa vs. resto** ($k = 2$, ARI = 0,57), perdendo a fronteira **versicolor/virginica**. No *Wine*, três plateaus diferentes ($k \in \{2, 6, 9\}$) têm **exatamente a mesma largura em τ** , evidenciando a fragilidade do critério “plateau mais largo” em datasets anisotrópicos — o desempate por menor k levou a $k = 2$ (subagrupamento), com ARI = 0,37. A geometria não-convexa das classes do *Wine* viola a esfericidade implícita do k-means.

Parzen + *mean-shift*. Excelente desempenho no *Wine* (ARI = 0,82). Não pressupõe forma esférica nem precisa de k a priori — modos emergem da densidade. Desvantagens: custo $O(n^2)$ por iteração e forte dependência de h . O plateau no número de modos vs. h é mais robusto que confiar apenas na regra de Silverman.

KNN-grafo mútuo. Melhor resultado no *Wine* (ARI = 0,87) e equivalente aos outros no *Iris*. É robusto a formas não-convexas, pois componentes conexas seguem a estrutura local do grafo. Desvantagem: a transição “muitas componentes pequenas $\rightarrow$ uma gigante” costuma ser abrupta, sem plateau útil em $K(k_{nb})$. A absorção de componentes pequenas e o critério “menor K_{post} + maior entropia” foram fundamentais para estabilizar a escolha.

Comparação geral. Os três métodos concordam no *Iris* (ARI = 0,57) — limitação intrínseca do dataset (sobreposição **versicolor/virginica**), não dos métodos. No *Wine*, a diferença (0,37 vs. 0,82 vs. 0,87) reflete que **abordagens baseadas em densidade e conectividade** lidam melhor com classes anisotrópicas que o k-means esférico.

Sensibilidade a parâmetros (resumo).

- BSAS: sensível à ordem (mediana de permutações resolve), à grade de τ e ao critério de seleção de plateau.
- Parzen: sensível a h ; a escolha por plateau no número de modos é mais robusta que Silverman puro.
- KNN-grafo: sensível a k_{nb} e ao limiar de `min_size` para reassign; o critério usado se mostrou estável em ambos os datasets.